

ANALSSYSI OF CORRELATION

ANALYSIS

2024-04-21

```
# Load the readxl package
```

```
library(readxl)
```

```
# Specify the file path to your Excel file
```

```
file_path <- "data_merged.xlsx"
```

```
# Read the Excel file into a dataframe
```

```
data_merged <- read_excel(file_path)
```

```
# Display the first few rows of the dataframe
```

```
head(data_merged)
```

```
## # A tibble: 6 x 21
##   departement Date      'Nb actuellement hospitalisés ' Nb actuellement en soi~1
##   <dbl> <chr>          <dbl>          <dbl>
## 1      75 2023-02-11      780            55
## 2      75 2021-05-20     1169           339
## 3      75 2020-12-26      774           139
## 4      75 2020-09-30      242            72
## 5      75 2022-02-08     1525           222
## 6      75 2021-11-14      121            21
## # i abbreviated name: 1: 'Nb actuellement en soins intensifs '
## # i 17 more variables: 'Total retour à domicile ' <dbl>, 'Total Décès ' <dbl>,
## #   'Nom departement ' <chr>, Sexe <chr>, population <chr>,
## #   'Densité de population ' <chr>, 'Taux de chômage ' <dbl>,
## #   'Nombre de residences surpeuplées ' <dbl>,
## #   'Taux de pauvreté au seuil de 60 % ' <dbl>, 'Part des 65 ans ou plus ' <dbl>,
## #   'Revenu fiscal moyen ' <dbl>, 'Age moyen ' <dbl>, ...
```

```
# Display the structure of the dataframe
```

```
str(data_merged)
```

```
## tibble [26,616 x 21] (S3: tbl_df/tbl/data.frame)
```

```
## $ departement
```

```
: num [1:26616] 75 75 75 75 75 75 7
```

```
## $ Date
```

```
: chr [1:26616] "2023-02-11" "2021-
```

```
## $ Nb actuellement hospitalisés
```

```
: num [1:26616] 780 1169 774 242 15
```

```
## $ Nb actuellement en soins intensifs
```

```
: num [1:26616] 55 339 139 72 222 2
```

```
## $ Total retour à domicile
```

```
: num [1:26616] 38316 19398 11060 4
```

```
## $ Total Décès
```

```
: num [1:26616] 6405 4381 2638 1171
```

```
## $ Nom departement
```

```
: chr [1:26616] "Paris" "Paris" "Pa
```

```
## $ Sexe
```

```
: chr [1:26616] "Tous" "Tous" "Tous
```

```
## $ population : chr [1:26616] "2145906" "2145906"
## $ Densité de population : chr [1:26616] "20359.599999999999"
## $ Taux de chômage : num [1:26616] 6.5 6.5 6.5 6.5 6.5
## $ Nombre de residences surpeuplées : num [1:26616] 146070 146070 14607
## $ Taux de pauvreté au seuil de 60 % : num [1:26616] 15 15 15 15 15 15 1
## $ Part des 65 ans ou plus : num [1:26616] 17.5 17.5 17.5 17.5
## $ Revenu fiscal moyen : num [1:26616] 3974 3974 3974 3974
## $ Age moyen : num [1:26616] 40 40 40 40 40 40 4
## $ Lits et places publics et privés installés au 31 décembre 2019: num [1:26616] 14643 14643 14643 1
## $ Indice de vieillissement (nombre de seniors pour 100 jeunes) : num [1:26616] 92 92 92 92 92 92 9
## $ Part des moins de 20 ans (en %) : num [1:26616] 18.9 18.9 18.9 18.9
## $ Maladies chroniques - Femmes : num [1:26616] 45.9 45.9 45.9 45.9
## $ Maladies chroniques - Hommes : num [1:26616] 49.6 49.6 49.6 49.6
```

#analysis

Calculate correlation between mortality and COVID-19 cases

```
correlation <- cor(data_merged$`Total Décès`, data_merged$`Nb actuellement hospitalisés`)
```

Print the correlation coefficient

```
print(correlation)
```

```
## [1] 0.3467621
```

Load required libraries


```
library(ggplot2)
```

Create a scatter plot with linear regression line

```
ggplot(data_merged, aes(x = `Nb actuellement hospitalisés`, y = `Total Décès`)) +
  geom_point() + # Scatter plot
  geom_smooth(method = "lm", se = FALSE, color = "blue") + # Linear regression line
  labs(x = "COVID-19 Cases (Currently Hospitalized)", y = "Total Deaths",
       title = "Relationship between Mortality and COVID-19 Cases",
       caption = "Data Source: Your Dataset") + # Labels and title
  theme_minimal() # Minimal theme
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

Relationship between Mortality and COVID-19 Cases



Data Source: Your Dataset


Le coefficient de corrélation entre la mortalité (Total Décès) et les cas de COVID-19 (Nb actuellement hospitalisés) dans l'ensemble de données est y 0,347. Cette corrélation positive suggère qu'il existe une relation positive modérée entre la mortalité et le nombre de cas de COVID-19. En d'autres termes, à mesure que le nombre de cas de COVID-19 augmente, le taux de mortalité tend à augmenter également, même si la corrélation n'est pas extrêmement forte.

Load required libraries

```
library(ggplot2)
```

Histogram of Mortality


```
ggplot(data_merged, aes(x = `Total Décès`)) +  
  geom_histogram(binwidth = 50, fill = "skyblue", color = "black") +  
  labs(x = "Total Deaths", y = "Frequency",  
       title = "Distribution of Mortality") +  
  theme_minimal()
```



Histogram of COVID-19 Cases

```
ggplot(data_merged, aes(x = `Nb actuellement hospitalisés`)) +
  geom_histogram(binwidth = 100, fill = "salmon", color = "black") +
  labs(x = "COVID-19 Cases (Currently Hospitalized)", y = "Frequency",
       title = "Distribution of COVID-19 Cases") +
  theme_minimal()
```


Distribution of COVID-19 Cases



Boxplot of Mortality and COVID-19 Cases

```
ggplot(data_merged, aes(x = factor(1), y = `Total Décès`)) +
  geom_boxplot(fill = "skyblue") +
  geom_boxplot(aes(y = `Nb actuellement hospitalisés`, fill = "salmon")) +
  labs(x = "", y = "Count",
       title = "Comparison of Mortality and COVID-19 Cases") +
  scale_x_discrete(labels = c("Mortality", "COVID-19 Cases")) +
  theme_minimal()
```

Comparison of Mortality and COVID-19 Cases



Density plot of Mortality and COVID-19 Cases

```
ggplot(data_merged, aes(x = `Total Décès`, fill = "Mortality")) +
  geom_density(alpha = 0.5, fill = "skyblue") +
  geom_density(aes(x = `Nb actuellement hospitalisés`, fill = "COVID-19 Cases"), alpha = 0.5, fill = "s
  labs(x = "Count", y = "Density",
        title = "Density Plot of Mortality and COVID-19 Cases") +
  scale_fill_manual(values = c("Mortality" = "skyblue", "COVID-19 Cases" = "salmon")) +
  theme_minimal()
```

Les visualisations fournissent des corrélations perspicaces :


Soins intensifs par rapport au nombre total de décès :

Il existe une corrélation positive entre le nombre moyen de patients en réanimation et le nombre total de décès dans les départements. Les départements comptant plus de patients en soins intensifs, comme Paris, ont également tendance à avoir un nombre total de décès plus élevé. Cela suggère que la charge pesant sur les unités de soins intensifs pourrait être un indicateur des taux de mortalité dus au COVID-19 dans ces régions.

Taux de pauvreté par rapport au nombre total de décès :

Il semble y avoir une tendance selon laquelle les départements ayant des taux de pauvreté plus élevés, comme la Seine-Saint-Denis, connaissent également un nombre de décès plus élevé. Cela met en évidence l'impact potentiel du statut socio-économique sur la gravité des conséquences de l'épidémie, où une pauvreté plus élevée peut être corrélée à un accès moindre aux ressources de santé ou à une plus grande prévalence de conditions préexistantes.

Density Plot of Mortality and COVID-19 Cases



```
import matplotlib.pyplot as plt
import seaborn as sns
```

```
data['Date'] = pd.to_datetime(data['Date'])
```

```
# Creating a summary table for COVID-19 data by department
covid_summary = data.groupby('Nom departement').agg({
    'Nb actuellement hospitalisés': 'mean',
    'Nb actuellement en soins intensifs': 'mean',
    'Total retour à domicile': 'sum',
    'Total Décès': 'sum',
    'population': 'mean',
    'Densité de population': 'mean',
    'Taux de chômage': 'mean',
    'Taux de pauvreté au seuil de 60 %': 'mean',
    'Part des 65 ans ou plus': 'mean',
    'Revenu fiscal moyen': 'mean',
    'Lits et places publics et privés installés au 31 décembre 2019': 'mean'
}).reset_index()
```

```
covid_summary.columns = [
    'Department', 'Average Hospitalized', 'Average in Intensive Care', 'Total Home Returns', 'Total
Deaths',
    'Population', 'Population Density', 'Unemployment Rate', 'Poverty Rate',
    'Percentage of 65+', 'Average Income', 'Hospital Beds'
]
```

```
covid_summary.head()
```

Résultat

	Department	Average Hospitalized	Average in Intensive Care \
0	Essonne	270.714157	36.348662
1	Hauts-de-Seine	497.262399	62.394049
2	Paris	591.269913	106.070634
3	Seine-Saint-Denis	491.501353	45.688308
4	Seine-et-Marne	223.332131	41.681695

	Total Home Returns	Total Deaths	Population	Population Density \
0	21610173	3852078	1306118.0	723.9
1	32672875	5596446	1626213.0	9260.4
2	47946064	9546728	2145906.0	20359.6
3	28866649	5031417	1655422.0	7008.6
4	21262586	4291732	1428636.0	241.5

	Unemployment Rate	Poverty Rate	Percentage of 65+	Average Income \
0	6.7	13.3	15.7	2581.0
1	6.5	11.9	12.0	3761.0
2	6.5	15.0	17.5	3974.0
3	10.8	27.9	15.3	1797.0
4	6.9	11.7	17.2	2439.0

	Hospital Beds
0	3351.0
1	7362.0
2	14643.0
3	4086.0
4	3521.0

Le tableau récapitulatif met en évidence les statistiques du COVID-19 et les facteurs socioéconomiques associés pour chaque département d'Île-de-France.

Paris compte le nombre moyen de patients hospitalisés et en réanimation le plus élevé, reflétant sa population et sa densité de population plus élevées.

La Seine-Saint-Denis se distingue par les taux de chômage et de pauvreté les plus élevés, ce qui pourrait être corrélé à son nombre de décès dus au COVID-19 relativement élevé malgré un revenu moyen inférieur et moins de lits d'hôpitaux par rapport à Paris.

Les Hauts-de-Seine présentent des indicateurs économiques relativement élevés (revenu moyen et faible taux de pauvreté) ainsi qu'un nombre élevé d'hospitalisations et de décès.

```

library(ggplot2)

# Scatter plot for Average in Intensive Care vs. Total Deaths
plot1 <- ggplot(covid_summary, aes(x = `Average in Intensive Care`, y = `Total Deaths`, size = Population,
color = Department)) +
  geom_point(alpha = 0.7) +
  scale_size_continuous(range = c(20, 200)) +
  labs(title = "Intensive Care vs. Total Deaths", x = "Average in Intensive Care", y = "Total Deaths") +
  theme_minimal()

# Scatter plot for Poverty Rate vs. Total Deaths
plot2 <- ggplot(covid_summary, aes(x = `Poverty Rate`, y = `Total Deaths`, size = `Population Density`,
color = Department)) +
  geom_point(alpha = 0.7) +
  scale_size_continuous(range = c(20, 200)) +
  labs(title = "Poverty Rate vs. Total Deaths", x = "Poverty Rate", y = "Total Deaths") +
  theme_minimal()

library(ggpubr)
ggarrange(plot1, plot2, nrow = 1, ncol = 2)

```

Ces résultats suggèrent que les départements les plus gravement touchés par le COVID-19, comme Paris et la Seine-Saint-Denis, font face à des défis distincts :

Paris est confrontée à des défis liés à une forte densité de population et à des demandes importantes en ressources de santé.

La Seine-Saint-Denis pourrait être affectée par des facteurs socio-économiques, notamment des taux de pauvreté et de chômage élevés, qui pourraient exacerber la crise sanitaire.